

<challenge> Synthetische Data

Bouw de synthetische populatie voor pandemische paraatheid

Hoe genereren we vanuit openbaar beschikbare CBS-buurtdata een synthetische populatie op microniveau die realistisch genoeg is om verspreiding van infectieziekten te modelleren?

Project	OneGov #2	Thema	Synthetische Data
Challenge owner	Marc Winsemius	Contact	hack@govtechnl.nl
Co-owners	Ruben Dood Tom Emery Ted Oliekan	Organisaties	CBS ODISSEI Erasmus MC
Datum	4-5 juni 2026	Locatie	The Hague Tech, Den Haag

Achtergrond

Wanneer een infectieziekte opduikt, is snel inzicht in hoe een virus zich verspreidt door een bevolking van levensbelang. Epidemiologische modellen zoals infection and recovery models kunnen die verspreiding in kaart brengen. Maar ze hebben daarvoor data op microniveau nodig: synthetische personen met realistische eigenschappen als leeftijd, woonsituatie, arbeidssector en mobiliteitspatroon.

Die microlevel data bestaat niet als openbaar beschikbaar bestand. Wat wel beschikbaar is, zijn geaggregeerde statistieken op buurt- en wijkniveau van CBS en RIVM: rijke, betrouwbare data, maar op een te grove schaal voor directe modellering. De uitdaging is om van die korrelige buurtaggregaten een synthetische populatie te genereren die statistisch klopt, ruimtelijk coherent is, en epidemiologisch betekenisvolle patronen behoudt.

Tegelijkertijd biedt rioolsurveillance het meten van pathogenen in rioolwater via rwzi's een vroeg signaalsysteem voor uitbraken. Hoe rijker de onderliggende synthetische dataset, hoe beter die signalen geografisch en demografisch geïnterpreteerd kunnen worden.

CBS, ODISSEI en Erasmus MC brengen deze twee werelden samen in deze challenge.

Probleemstelling

Onderzoekers en beleidsmakers die pandemische scenario's willen modelleren, lopen steeds opnieuw tegen dezelfde muren aan:

- Microlevel populatiedata is niet openbaar beschikbaar. Echte persoonsgerelateerde data is privacygevoelig en daarmee onbruikbaar voor brede modellering.
- Geaggregeerde CBS-buurtdata is rijk, maar te grof. Infection and recovery models hebben individuele synthetische personen nodig, niet buurtsommaties.
- Er is geen gestandaardiseerde methode om van buurtstatistieken een synthetische populatie te bouwen die ook ruimtelijke coherentie en cross-domain relaties behoudt.
- Rioolsurveillance datasets missen de demografische en ruimtelijke context die nodig is om signalen goed te kunnen interpreteren.

De challenge

Hoe genereren we, op basis van uitsluitend openbaar beschikbare data, een synthetische populatie op microniveau die statistisch klopt met CBS-buurtaggregaten, ruimtelijke structuur behoudt, en bruikbaar is als input voor infection and recovery models en rioolsurveillance?

De kerntaak is het bouwen van een synthetische representatie van Nederland op microniveau, vertrekkend vanuit geaggregeerde buurtdata. Vergelijk het met een algoritme dat een korrelige foto opschaaft naar hogere resolutie: de output bevat meer detail dan de input, maar blijft statistisch consistent met het origineel.

Teams kiezen een van de twee lagen als focuspunt, of laten zien hoe beide samenhangen:

Laag 1 - Demografische populatie

Genereer synthetische personen of huishoudens die demografisch en sociaaleconomisch overeenkomen met de CBS-buurtstatistieken.

Epidemiologisch relevant:

- Leeftijdsverdeling en huishoudsamenstelling
- Woningtype en bezettingsgraad
- Arbeidssector en mobiliteitspatroon
- Ruimtelijke locatie op buurniveau

Laag 2 - Riolsurveillance context

Koppel de synthetische populatie aan RWZI-gegevens en landgebruiksdata zodat rioolsignalen geografisch en demografisch geïnterpreteerd kunnen worden.

Metagenomics-relevant:

- RWZI-locatie, catchment-oppervlak en aansluitingen
- Landgebruik binnen het stroomgebied
- Nabijheid van transport- en verzamelplaatsen
- Koppeling populatiedichtheid aan rioolinfrastructuur

Richtinggevende vragen voor teams

De challenge owners hebben vier vragen geformuleerd als kompas:

- Hoe genereer je synthetische individuen die statistisch consistent zijn met buurtgemiddelden, zonder toegang tot echte persoonsdata?
- Hoe bewaar je cross-domain relaties, zodat leeftijd, woningtype, arbeidssector en inkomen van een synthetisch persoon een realistisch geheel vormen?
- Hoe zorg je voor ruimtelijke coherentie, zodat de synthetische populatie van een buurt ook geografisch geloofwaardig is ten opzichte van omliggende buurten?
- Hoe maak je de dataset bruikbaar voor zowel infectiemodellen als rioolsurveillance, gegeven de verschillende ruimtelijke schaalniveaus van die twee toepassingen?

Wie je helpt: de gebruiker

Je bouwt een synthetische dataset, maar je ontwerpt voor mensen die er straks mee werken. Hieronder twee persona's die de diversiteit in gebruik weerspiegelen.

01

Lena

Epidemioloog, RIVM

Lena modelleert de verspreiding van luchtweginfecties in stedelijke gebieden. Ze heeft microlevel populatiedata nodig om haar infection and recovery models te voeden, maar kan niet werken met echte persoonsgegevens. Ze wil een dataset die demografisch realistisch is en die ze direct kan inladen in haar Python-omgeving.

Loopt tegen aan:

- Publiek beschikbare data is geaggregeerd op buurniveau, te grof voor haar modellen.
- Zelf synthetische populaties bouwen kost weken; ze heeft geen tijd voor dataverzameling.
- Ze weet niet of de cross-domain relaties in de data kloppen, en kan dat moeilijk valideren.

"Als ik niet weet of de dataset epidemiologisch realistisch is, kan ik de modeluitkomsten niet vertrouwen."

02

Daan

Data-analist rioolsurveillance, Erasmus MC

Daan analyseert pathogeenconcentraties in rioolwater van tientallen rwzi's in Nederland. Hij wil signalen uit het rioolwater koppelen aan de demografische en ruimtelijke context van het verzorgingsgebied, maar die context ontbreekt. Een synthetische populatie gekoppeld aan rwzi-catchments zou zijn analyses direct verrijken.

Loopt tegen aan:

- RWZI-stroomgebieden bevatten geen demografische informatie over de bewoners.
- Hij kan pieken in pathogenen niet verklaren zonder te weten wat voor populatie er woont.
- Koppeling van ruimtelijke en demografische lagen kost nu veel handmatig werk per regio.

"Een rioolsignaal zonder populatiecontext is een alarm zonder adres."

Startpositie: open source en open data

Deze challenge is volledig gebaseerd op openbaar beschikbare bronnen. Dat geldt voor zowel de data als de software.

Data: alle variabelen zijn afkomstig uit CBS StatLine, het RWZI-register (Emissieregistratie.nl) en open GIS-bronnen van RIVM en NRS. Gesloten data of data achter een betaalmuur is uitdrukkelijk uitgesloten. Teams laten in hun inzending zien welke databronnen ze hebben gebruikt.

Software: teams zijn vrij in hun technische aanpak. Als referentie en inspiratie staat de open source library MetaSyn beschikbaar (github.com/sodascience/metasynt). Gebruik hiervan is niet verplicht. Vereiste is wel dat de ontwikkelde code en methodologie na de hackathon open source beschikbaar worden gesteld.

Variabelen en databronnen

De volledige variabellenlijst met CBS-tabelnummers, prioritering (must/should/could have) en directe links naar alle databronnen is beschikbaar in de GitHub-repository:

github.com/govtechnl/onegov2-synthetic-data

De repository bevat:

- docs/variables.md: de volledige variabelentabel met prioritering en CBS-tabelnummers
- data/sources.yaml: alle databronnen met URL en licentie
- docs/kwaliteitsrapport-template.md: template voor de verplichte kwaliteitsrapportage bij de inzending
- tooling/starterfetchers voor CBS StatLine en het RWZI-register, plus voorbeeldscripts

Beoordelingscriteria

Teams worden beoordeeld door een vakjury met expertise in epidemiologie, data science en open source ontwikkeling, waaronder Ted Oliekan (Erasmus MC). Vier niveaus:

✓ **Moet: Minimale vereisten voor een geldige inzending**

- De inzending bevat een synthetische dataset op microniveau (persoons- of huishoudensniveau) voor minimaal een Nederlandse regio.
- De dataset is aantoonbaar gebaseerd op uitsluitend openbaar beschikbare bronnen; een overzicht van gebruikte databronnen is onderdeel van de inzending.
- De ontwikkelde code en methode zijn open source gepubliceerd, bijvoorbeeld via GitHub.
- De dataset bevat minimaal de must-have variabelen zoals beschreven in docs/variables.md in de repository.

★ **Zou moeten: Onderscheidende kwaliteiten**

- De dataset behoudt cross-domain relaties: variabelen van een synthetisch individu vormen een intern consistent geheel.
- De dataset heeft ruimtelijke coherentie: buurtpopulaties zijn realistisch ten opzichte van omliggende buurten.
- De output bevat kwaliteitsparameters die laten zien hoe goed de synthetische data overeenkomt met de bronstatistieken.
- Riolsurveillance-variabelen (RWZI, catchment, landgebruik) zijn gekoppeld aan de demografische laag.

⚠ **Zou niet: Valkuilen om te vermijden**

- Gebruik van gesloten of betaalde databronnen zonder vermelding.
- Een dataset die alleen buurtaggregaten herformateert zonder echte microlevel synthetisering.
- Code of methode die niet reproduceerbaar is of niet open source beschikbaar wordt gesteld.

✨ **Kan: Bonus voor uitmuntende inzendingen**

- De synthetische populatie is gevalideerd als input voor een werkend infection and recovery model.
- Small-area realism: de dataset presteert ook op sub-buurniveau realistisch.
- Epidemiologisch betekenisvolle patronen zijn aantoonbaar aanwezig, bijvoorbeeld clustervorming van kwetsbare groepen.
- De aanpak is overdraagbaar: de methode werkt ook voor andere regio's of tijdspunten.

Wat lever je op?

Aan het einde van de hackathon levert elk team het volgende op Alkemio:

- Een synthetische dataset (als open bestand, bijvoorbeeld CSV of Parquet) voor minimaal een Nederlandse regio.
- De broncode en methodebeschrijving, open source gepubliceerd via GitHub
- Een overzicht van gebruikte databronnen en een kwaliteitsrapportage van de dataset.
- Een pitch (max. 3 minuten): welke aanpak hebben jullie gekozen, wat zijn de sterktes en beperkingen, en hoe is de dataset bruikbaar voor pandemische modellering?
- Een pitch deck (maximaal 10 slides).

Resources en startmateriaal

Alle benodigde databronnen zijn openbaar beschikbaar. Hieronder een overzicht:

Bron	Beschikbaar via
CBS StatLine	statline.cbs.nl: Kerncijfers wijken en buurten (86165NED), Bodemgebruik (70262NED), Nabijheidsstatistieken (85870NED), ODin (84709NED)
RWZI-register	emissieregistratie.nl: locaties, capaciteiten en stroomgebieden van rioolwaterzuiveringsinstallaties
RWZI-stroomgebiedskaart (PDOK)	Stedelijk Water (Riolering) GWSW: open wfs met catchment-gebieden per RWZI
BAG (open)	bag.basisregistraties.overheid.nl: basisregistratie adressen en gebouwen
MetaSyn (referentie, optioneel)	github.com/sodascience/metasync: open source library voor synthetische data
GreenPT API	greenpt.nl: API-toegang voor teams die LLM-calls willen integreren

 Marc Winsemius (Digicampus) is de challenge owner en coördineert vanuit de organiserende kant. Ruben Dood (CBS), Tom Emery (ODISSEI) en Ted Oliekan (Erasmus MC) zijn co-owners en beschikbaar voor inhoudelijke vragen over epidemiologische modellering en synthetische data.

Technisch kader

Bij het bouwen van de synthetische dataset kom je een aantal methodologische keuzes tegen. Hieronder de belangrijkste:

Synthetiseringsmethoden:

- Gangbare aanpakken zijn iterative proportional fitting (IPF), agent-based populatiegeneratie of generatieve modellen. Teams kiezen zelf hun methode; de keuze moet worden onderbouwd in de pitch.

Schaalniveau:

- De brondata is beschikbaar op buurt- en wijkniveau. De synthetische output moet op microniveau zijn (personen of huishoudens), maar hoeft niet voor heel Nederland gegenereerd te worden. Een aantoonbaar schaalbare aanpak op een representatieve regio is voldoende.

Privacy by design:

- De dataset mag nooit herleidbaar zijn tot echte individuen. Teams laten zien welke privacymaatregelen zijn genomen, zoals disclosure protection of k-anonymity.

Open source vereiste:

- Alle code en methodebeschrijvingen worden na de hackathon open source beschikbaar gesteld. De synthetische dataset zelf wordt gepubliceerd als open bestand.

Disclaimer

De synthetische datasets en methoden die voortkomen uit deze hackathon worden gepubliceerd als open source. Opname in vervolgonderzoek of beleidsprogramma's is afhankelijk van verdere kwaliteitsbeoordeling door de challenge owners. De challenge is bedoeld als innovatieoefening; datasets vereisen aanvullende validatie voor gebruik in operationele modellen.

Challenge owner: Marc Winsemius (marc.winsemius@logius.nl) • Co-owners: Ruben Dood (r.dood@cbs.nl) • Tom Emery (tom@odisseei-data.nl) • Ted Oliekan (t.oliekan@erasmusmc.nl)

Vragen over de hackathon: hack@govtechnl.nl